


LLM 에이전트 Tool Call 데이터 유출 탐지를 위한 한국어 특화 가드레일 모델

서울대학교 소프트웨어학과 김지우(32181070)

연구 배경 및 문제 정의

- 기존 가드레일(Llama Guard 등)은 대화 레벨 안전성에 집중하여 Tool Call 단계의 위험을 감지하지 못함
- LLM 에이전트가 외부 Tool(API, DB, 파일)을 호출하는 순간의 데이터 유출은 시각적·청각적 노출 위험
- 한국어 환경에서 Llama Guard 3의 F1 Macro ≈ 0.61 — 성능 저하 심각
- 주민등록번호, 계좌번호 등 한국 고유 PII 패턴 미지원



미감지 분류기준 우선순위: S3 > S5 > S1 > S2 > S4

safe 정상 공개정보 검색, 날씨 조회	S1 PII 유출 주민번호, 계좌번호 노출	S2 Credential API 키, DB 비밀번호 노출
S3 Prompt Injection 숨겨진 명령, 에이전트 탈취	S4 데이터 외부 전달 DB 결과 미승인 전송	S5 System Prompt 추출 내부 지시사항, 로직 노출


시스템 아키텍처

2단계 파이프라인 + 3단 플렉스 추론


DETECTION PIPELINE



GUARDRAIL INPUT FIELDS



MODEL SERVING



학습 방법론

Kanana-nano-2.1b · LoRA SFT · 한국어 합성 데이터 7,000건

TRAINING CONFIG

BASE MODEL	Kanana-nano-2.1b-instruct KakaoAI · 한국어 특화	합성 7,000건 도메인 구성	● 금융 30%
FINE-TUNING	LoRA SFT rank=16, alpha=32, dropout=0.05		● 개발 20%
TARGET	q_proj · k_proj · v_proj · o_proj		● 의료 15%
DATASET	합성 7,000건 · 6개 도메인		● 일반 15%
HARDWARE	NVIDIA A10G 24GB CUDA 12.1 · Flash Attn 2		● 법률 10%
OPTIMIZER	AdamW + Cosine LR Decay lr=2e-4 · warmup=5% · bs=16		● HR 10%

DETECTION PRIORITY · 통시 위반 시 상위 분류

1 S3 Prompt Injection CRITICAL	2 S5 System Prompt HIGH	3 S1 PII 유출 HIGH	4 S2 Credential MEDIUM	5 S4 데이터 전달 MEDIUM
--------------------------------------	-------------------------------	------------------------	------------------------------	--------------------------

RATIONALE · 시스템 탈취(S3)는 후속 모든 위협을 유발 → 최우선 · 자격증명 노출(S2)은 패턴 매칭으로 후처리 가능

참고문헌

- [1] Meta AI. Llama Guard 3. 2024.
- [2] Li et al. InjecGuard: Benchmarking and Mitigating Over-defense in Prompt Injection Guardrail Models. arXiv:2410.22770. 2024.
- [3] Hackett et al. Bypassing Prompt Injection Detection in LLM Guardrails. arXiv:2504.11168. 2025.
- [4] de Witt. Open Challenges in Multi-Agent Security. arXiv:2505.02077. 2025.
- [5] Kakao AI. Kanana: Compute-efficient Bilingual Language Models. 2025.

Links



파인튜닝 결과

프롬프트 반복 개선 → 모델 종합 성능평가 및 시각화

FIG. 1 시스템 프롬프트 반복 개선을 통한 성능개선




그림 1 시스템 프롬프트 반복 개선에 따른 성능 변화. v2에서 우선순위 규칙 추가로 +18.8%p 향상, v4에서 S3/S5 기반 명시 및 safe 관련 기준 강화로 FPR 0% 달성.

FIG. 2 카테고리별 F1 Score



그림 2 v4 기준 카테고리별 F1 점수. S2(Credential), S3(Prompt Injection), S5(시스템 추출)에서 F1 1.000 달성. 전선은 목표 F1 ≥ 0.90.

FIG. 3 모델 비교 — F1 · FPR · 추론 지연




그림 3 한국어 Tool Call 환경에서의 모델 비교. Llama Guard 3 대비 F1 +53%p 향상(0.61→0.940), FPR 11.2%→0.0% 달성.

FIG. 4 혼동 행렬(Confusion Matrix)



그림 4 정확도 94.0%, FPR 0.0%. 전역 오류 3건은 S4+S5 경계 케이스로 실용적 관점에서 허용 가능.

FIG. 5 Kanana Fine-Tuned 모델의 추론 속도 순위




그림 5 v4는 FPR-FNR 축에서 완전한 성능. Kanana 파인튜닝 모델은 추론 속도에서도 우수.

KEY FINDING

- Llama Guard 3 대비 한국어 환경에서 F1 +53%p 향상 (0.61 → 0.940), FPR을 11.2% → 0.0%로 낮춰 운영 안정성 확보 · 프롬프트 반복 개선을 통한 비약적 성능향상

SUMMARY · BENCHMARK

모델	F1 Macro	FPR	지연(ms)	비고
Llama Guard 3	0.61	11.2%	800	영어, 한국어 베이스라인
Kanana-2.1B SFT	0.81	6.2%	200	경량 · 최고 속도
Kanana-8B SFT	0.87	3.0%	500	대형 · F1 최고
Prototype v4 ★	0.94	0.0%	1837	기준선 · 오탐 0건

결론 및 기여

- 한국어 Tool Call 보안 탐지 최초 가드레일
한국어 환경 + Tool Call 전용 분류기
- 7,000건 한국어 합성 데이터셋 공개
HuggingFace · 6개 도메인 커버리지
- 프롬프트 반복 개선 · FPR 0% 달성
오탐 0건 · 운영 환경 적용 가능
- 2단계 파이프라인 · 라이브 데모 구현
실제 동작 시스템으로 검증

향후 계획

- Kanana-8B DPO를 통한 과탐 감소
F1 ≥ 0.90, FPR ≤ 3%
- 운영 데이터 RL
실 트레이닝 강화 학습
- 멀티에이전트
에이전트 간 상호작용 보안