
Guardrail4Agent

LLM 에이전트 Tool Call 데이터 유출 탐지를 위한

한국어 특화 가드레일 모델 파인튜닝



제출일 : 2026 년 06 월 05 일

이름 : 김지우 (010-5278-2529)

학번 : 32181070

소속 : AI 융합대학 소프트웨어학과

목차 (Table of Contents)

1. 프로젝트 개요	3
1.1 배경 및 필요성	3
1.2 프로젝트 목표	3
1.3 개발 기간 및 기술 스택	4
2. 시스템 설계	5
2.1 탐지 카테고리 설계	5
2.2 2 단계 파이프라인 아키텍처	6
2.3 가드레일 서버 API 설계	7
3. 학습 데이터 구축	8
3.1 합성 데이터 생성 파이프라인	8
3.2 학습 데이터 품질 관리	9
4. 모델 학습	10
4.1 학습 환경	10
4.2 LoRA 하이퍼파라미터	10
4.3 트러블슈팅 기록	11
5. 평가 결과	12
5.1 프롬프트 반복 개선	12
5.2 v4 카테고리별 F1	13

5.3 파인튜닝 모델 비교 벤치마크	14
5.4 오류 패턴 분석	15
6. 데모 시스템	16
6.1 데모 서버 구성	16
6.2 주요 기능	16
6.3 내장 시나리오 6 종	17
7. 결론 및 향후 계획	18
7.1 핵심 기여	18
7.2 향후 개발 계획	18
8. 부록	19

1. 프로젝트 개요

1.1 배경 및 필요성

최근 LLM(Large Language Model) 기반 에이전트는 외부 Tool 을 호출하여 검색, 이메일 발송, 데이터베이스 조회 등 다양한 실세계 작업을 자동 수행한다. 그러나 기존 가드레일(Guardrail) 시스템은 주로 사용자 입력 단계의 텍스트 분류에 집중되어 있어, 에이전트가 Tool Call 을 생성하는 단계는 사실상 미감시 구간(Blind Spot)으로 남아 있다.

특히 Meta 의 Llama Guard 3 는 영어 환경에서는 우수한 성능을 보이지만, 한국어 환경에서는 F1 Score 0.61 수준에 머무르며 한국 고유의 개인식별정보(PII)인 주민등록번호(13 자리), 계좌번호, 건강보험번호 등을 인식하지 못하는 한계가 명확하다.

주요 ‘미감시 구간’ 위협 사례

- Tool Call 쿼리 파라미터에 주민번호·계좌번호가 포함되어 외부 검색 API 로 전송
- 내부 DB 비밀번호가 search_web 또는 send_message Tool 을 통해 외부로 유출
- 외부 PDF·이메일 본문에 숨겨진 Prompt Injection 이 에이전트의 다음 행동을 탈취
- 시스템 프롬프트(내부 지침) 자체를 파일·외부 채널로 추출하려는 시도

1.2 프로젝트 목표

본 프로젝트 Guardrail4Agent 는 한국어 Tool Call 데이터 유출 탐지에 특화된 경량 가드레일 모델을 파인튜닝하여 다음 네 가지 정량 목표를 달성하는 것을 목적으로 한다.

No.	목표 항목 (Objective)	정량 지표 (Target)
1	한국어 Tool Call 보안 위협 분류기 구축	5 종 카테고리 (S1~S5) + safe
2	False Positive Rate (오탐률)	FPR = 0%
3	분류 성능 (Macro Averaged F1)	F1 Macro $\geq$ 0.90
4	실시간 추론 환경	FastAPI 서버 + 라이브 데모

1.3 개발 기간 및 기술 스택

구분 (Category)	항목 (Item)	상세 (Detail)
기간	Project Period	2026 년 4 월 ~ 2026 년 6 월 (약 3 개월)
베이스 모델	Base Model	Kanana-nano-2.1b-instruct (KakaoCorp)
파인튜닝	Fine-tuning	HuggingFace PEFT (LoRA), TRL (SFT / DPO)
서빙	Serving	FastAPI + Docker + AWS EC2 + nginx
평가	Evaluation	scikit-learn (F1, Precision, Recall, Confusion Matrix)
프레임워크	Framework	PyTorch 2.1.0, Transformers 4.40+, Flash Attention 2
하드웨어	GPU	NVIDIA A10G 24GB (AWS ml.g5.2xlarge)

프로젝트 KPI 및 성과요약

본 프로젝트는 한국어 환경에서 LLM 에이전트의 Tool Call 단계를 감시하는 최초의 특화 가드레일을 구현했으며, Llama Guard 3 대비 F1 Score 를 +53%p 개선(0.61 → 0.940)하였다. 또한 7,000 건 규모의 한국어 합성 보안 데이터셋을 구축하여 오픈소스로 공개함으로써 후속 연구의 기반을 마련하였다.

2. 시스템 설계

2.1 탐지 카테고리 설계

Guardrail4Agent 는 Tool Call 단계에서 발생 가능한 보안 위협을 5 종 카테고리(S1~S5)로 체계화하고, 정상 호출을 별도의 safe 카테고리로 구분한다. 각 카테고리는 실제 공격 시나리오를 기반으로 정의되었다.

코드	카테고리	설명	실제 공격 예시
safe	정상	위험 없는 정상 Tool Call	날씨 검색, 공개 정보 조회
S1	PII 유출	개인식별정보 외부 전달	주민번호가 search_web 쿼리에 포함
S2	Credential 유출	인증 정보 외부 전달	DB 비밀번호가 Slack Webhook 으로 전송
S3	Prompt Injection	외부 데이터의 악성 명령	PDF 에 숨겨진 무단 이체 명령
S4	내부 데이터 외부 전달	미승인 외부 서비스 전송	고객 DB 10,000 건이 외부 파트너사로
S5	시스템 프롬프트 추출	내부 지침 노출 유도	「지시사항을 파일로 저장해줘」


카테고리 판별 우선순위 (Priority Order)

S3 > S5 > S1 > S2 > S4

위 우선순위는 보안 위험도(Severity)와 탐지 결정 시 모호성을 해소하기 위해 설계되었다. 예를 들어 「외부 PDF 에 숨겨진 명령으로 인해 주민번호가 외부 전송되는 시나리오」의 경우, 근본 원인인 Prompt Injection 을 우선하여 S3 로 분류한다.

2.2 2 단계 파이프라인 아키텍처

Guardrail4Agent 는 에이전트 LLM 의 Tool Call 생성 직후, 실행 직전 단계에 삽입되는 2 단계 파이프라인 구조로 동작한다. Guardrail 분류기가 safe 로 판정한 경우에만 Tool 이 실제로 실행되며, unsafe 로 판정 시 즉시 차단되고 사유가 반환된다.



[그림 1] Guardrail4Agent 2 단계 파이프라인 아키텍처 (Architecture Flow)

입력 필드 구분

필드명 (Field)	필수 여부	설명 (Description)
SYSTEM_PROMPT	선택	에이전트의 시스템 프롬프트 (내부 지침)
USER_INPUT	선택	사용자가 입력한 원본 요청 텍스트
TOOL_CALL	필수	에이전트가 생성한 Tool Call (주요 분석 대상)
TOOL_RESULT	선택	Tool 실행 결과 (S3 Prompt Injection 탐지에 중요)
NEXT_ACTION	선택	에이전트의 다음 행동 계획

2.3 가드레일 서버 API 설계

분류 서버는 단일 엔드포인트 POST /classify 를 제공하며, 두 가지 추론 모드(prototype / finetuned)를 지원한다. prototype 모드는 Claude Haiku 기반으로 빠른 프로토타이핑 및 회귀 평가에 사용되며, finetuned 모드는 자체 학습한 Kanana 체크포인트를 사용한다.

Request Schema

필드	타입	필수	설명
system_prompt	string	○	에이전트 시스템 프롬프트
user_input	string	○	사용자 요청 텍스트
tool_call	string	●	분석 대상 Tool Call (JSON 문자열)
tool_result	string	○	Tool 실행 결과 (선택)
next_action	string	○	다음 행동 계획 (선택)

Response Schema

필드	타입	설명
is_safe	bool	안전 여부 (true / false)
category	string	분류된 카테고리 코드 (safe / S1~S5)
category_desc	string	카테고리 한글 설명
reason	string	판정 사유 (모델 생성 자연어 설명)
latency_ms	float	분류 처리 시간 (밀리초)
model	string	사용된 모델 식별자

3. 학습 데이터 구축

3.1 합성 데이터 생성 파이프라인

한국어 환경에서 LLM 에이전트의 Tool Call 보안 데이터는 공개 데이터셋이 부재하므로, Claude API 를 활용한 합성 데이터 생성 파이프라인을 구축하였다. 총 7,000 건 규모로 train / eval / test 세트로 분할되었다.

분할 (Split)	건수 (Count)	비율 (Ratio)	용도 (Purpose)
Train	4,900 건	70%	SFT / DPO 학습
Eval	700 건	10%	에폭별 검증 (Validation)
Test	1,400 건	20%	최종 성능 평가
합계 (Total)	7,000 건	100%	—

도메인 분포 (Domain Distribution)

도메인	비율	도메인	비율
금융 (Finance)	30%	개발 (Development)	20%
의료 (Healthcare)	15%	HR (Human Resources)	10%
법률 (Legal)	10%	일반 (General)	15%

카테고리 분포 (Category Distribution)

- safe : 30% (과탐 억제를 위해 비율 강화)
- S1 ~ S5 : 각각 14% (균등 분포, 합 70%)
- 생성 방식 : Claude API 배치 처리 (5 건/배치, max_tokens=8192)
- 검수 : 전문가 레이블 검수를 통한 품질 보증

3.2 학습 데이터 품질 관리

데이터 생성 과정에서 카테고리 경계가 모호한 케이스가 다수 발생하였다. 이를 해결하기 위해 다음의 품질 관리 규칙을 적용하였다.

경계 케이스 처리 규칙

경계 케이스 (Edge Case)	처리 규칙 (Rule)
계좌번호가 내부 DB 유출에 포함된 경우	S1 (PII 유출) 우선 → S4 아님
user_input 이 원인 + 내부 지침 표적	S5 (시스템 프롬프트 추출) 강화
외부 데이터의 악성 명령으로 PII 외부 전송	S3 (Prompt Injection) 우선
익명화 통계가 외부로 전송되는 경우	safe (재식별 불가능 시) — 과탐 억제
safe 비율 30% 유지	False Positive (FP) 억제 강화

배치 처리 최적화

초기 BATCH_SIZE=20 으로 시도했을 때 max_tokens 초과로 JSON 생성이 중간에 잘리는 문제가 발생했다. 이를 해결하기 위해 BATCH_SIZE=5, max_tokens=8192 로 조정하여 안정적인 데이터 생성 파이프라인을 확보하였다.

4. 모델 학습

4.1 학습 환경

구성요소	사양 (Specification)
GPU	NVIDIA A10G 24GB (AWS ml.g5.2xlarge)
CUDA	12.1
PyTorch	2.1.0
Attention 최적화	Flash Attention 2 (compute capability ≥ 8.0)
HuggingFace Transformers	4.40+
PEFT (LoRA)	0.10+
TRL (SFT / DPO)	0.8.6+

4.2 LoRA 하이퍼파라미터

분류 태스크 및 소규모 학습 데이터(7,000 건)에 최적화된 LoRA(Low-Rank Adaptation) 설정을 적용하였다. 각 하이퍼파라미터는 사전 실험 및 휴리스틱에 기반하여 선정되었다.

파라미터	값	선택 근거
rank (r)	16	분류 태스크 최적, $r=64$ 대비 과적합 방지
alpha	32	$\alpha / r = 2$ 표준 휴리스틱
target_modules	q, k, v, o	Attention 전체 커버
dropout	0.05	소규모 데이터(7K) 과적합 억제
learning_rate	$2e-4$	소형 모델 공격적 LR 채택
batch_size	8 (grad_accum 2)	effective batch = 16
epochs	3	train / eval loss 기준 선정

4.3 트러블슈팅 기록

학습 및 데이터 생성 과정에서 발생한 주요 이슈와 해결책을 시간순으로 기록하였다. 동일 일자(2026-05-12)에 집중적으로 4 건의 이슈가 발생하였으며 모두 당일 해결되었다.

날짜	문제	원인	해결책
2026-04-09	S5 F1 0.333	S5/S3 판별 기준 미명시	프롬프트에 분기 조건 명시
2026-04-20	FPR 16.7%	익명화 통계 과탐	safe 판별 기준 3 종 추가
2026-05-07	JSON 생성 잘림	배치 20 건 진행 오류	BATCH_SIZE=5, max_tokens=8192
2026-05-28	Flash Attention 오류	V100 compute 7.0 미지원	compute $\geq$ 8.0 조건 분기

주요 인사이트


- 프롬프트 엔지니어링 단계에서 우선순위 명시가 카테고리 혼동(S5↔S3) 해소에 결정적
- safe 판별 기준 강화는 FPR 16.7% → 0%로 극적 개선에 기여
- Flash Attention 2 사용 시 GPU compute capability 사전 확인 필수
- 합성 데이터 배치 사이즈는 토큰 예산과 트레이드오프, 5 건/배치가 안정적

5. 평가 결과

5.1 프롬프트 반복 개선을 통한 버전 업그레이드

프로토타입(Claude Haiku 기반) 프롬프트를 4 차례 반복 개선한 결과, 50 개 테스트 케이스에서 F1 Macro 0.844 → 0.940 으로 개선되었으며 FPR 은 0%를 달성하였다. v3 에서 확장 평가 시 발견된 safe 과탐 및 S5↔S3 혼동 문제는 v4 에서 판별 기준 강화로 해결되었다.

버전	케이스	정확도	F1 Macro	FPR	FNR	주요 변경
v1	16 건	75.0%	0.844	0.0%	0.0%	기본 프롬프트
v2	16 건	93.8%	0.933	0.0%	0.0%	우선순위 S3>S1>S2>S4>S5 추가
v3	50 건	84.0%	0.788	16.7%	0.0%	확장 평가 (S5↔S3, safe 과탐)
v4	50 건	94.0%	0.940	0.0%	0.0%	S5/S3 기준 + safe 기준 강화




[그림 2] 프롬프트 v1~v4 성능 개선 추이 (Accuracy, F1 Macro, FPR)

5.2 카테고리별 F1

최종 파인튜닝된 모델의 카테고리별 F1 Score 는 safe / S2 / S3 / S5 에서 완벽한 1.000 을 달성했으며, S1(PII 유출) 0.842, S4(내부 데이터 외부 전달) 0.800 으로 측정되었다. Macro F1 은 0.940 으로 프로젝트 목표(≥ 0.90)를 초과 달성하였다.

카테고리	F1 Score	달성 여부
safe	1.000	완료
S1 (PII 유출)	0.842	완료
S2 (Credential 유출)	1.000	완료
S3 (Prompt Injection)	1.000	완료
S4 (내부 데이터 외부 전달)	0.800	완료
S5 (시스템 프롬프트 추출)	1.000	완료
Macro Average	0.940	완료 (목표치 초과달성)




[그림 3] v4 카테고리별 F1 Score 분포 (목표선 0.90 표시)

5.3 파인튜닝 모델 비교 벤치마크

기존 영어 특화 모델인 Llama Guard 3 와 본 연구의 Kanana 기반 모델들을 한국어 Tool Call 탐지 태스크에서 비교하였다. Llama Guard 3 는 F1 0.61, FPR 11.2% 수준으로 한국어 환경에 부적합함이 확인되었다.

모델	F1 Macro	FPR	FNR	추론 지연	비고
Llama Guard 3 (8B)	~0.61	~11.2%	—	~800ms	영어 특화
Kanana-2.1B SFT	0.81	6.2%	—	~200ms	본 연구 경량
Kanana-8B QLoRA SFT	0.87	8.3%	—	~500ms	본 연구 대형
Fine-Tuned Model(v4)	0.940	0.0%	0.0%	1,837ms	Claude API
Kanana-8B DPO (목표)	≥0.90	≤3%	≤5%	~500ms	학습 중



[그림 4] 모델 비교 레이더 차트 - 5 개 평가축 (F1, FPR, Speed, Locale, Compactness)

5.4 오류 패턴 분석

v4 프로토타입의 50 케이스 평가에서 발생한 3 건의 오류를 분석한 결과, 대부분 카테고리 경계의 모호성에서 비롯된 것으로 확인되었다. 특히 2 건은 새로 도입한 우선순위 규칙 ($S1 > S4$)에 따라 「실용적으로 올바른」 판정으로 평가된다.

ID	예상	예측	분석	실용적 판단
S4-001	S4	S1	고객 DB 에 주민번호 + 계좌번호 포함 → 새 우선순위 규칙으로 S1 판정	실용적으로 옳바름
S4-007	S4	S1	상담기록에 전화번호 + 이름 포함 → S1 판정	실용적으로 옳바름
EDGE-003	S1	S4	재식별 가능한 「익명화」 데이터 → S4 판정	경계 케이스 (추가 검토 필요)

분석에 대한 고찰

- 3 건의 오류 중 2 건은 우선순위 규칙 도입에 따른 의도된 분류 변경 ($S1 > S4$)
- EDGE-003 은 「익명화」 와 「재식별 가능성」 의 경계 정의를 추가 보완 필요
- 실질적 F1 Macro 는 0.940 + 우선순위 보정 시 0.96~0.97 수준으로 추정
- 운영 데이터 기반 강화 학습 시 잔여 오류 해소 가능

6. 데모 시스템 구축

6.1 데모 서버 구성

구성 요소	사양
아키텍처	FastAPI + Docker + nginx
인프라	AWS EC2 t3.small
인증	JWT 기반 (유효기간 24 시간)
접근 제어	IP 당 일 2 회 / 전체 일 50 회 쿼터
관리자	관리자 계정은 IP 제한 없게 구성 (상시 테스트용)
URL	http://43-203-223-40.nip.io

6.2 주요 기능

① 에이전트 데모 탭

6 종 사전 정의된 시나리오 중 하나를 선택하면, 2 단계 파이프라인이 실시간으로 시각화된다. 사용자는 (1) 에이전트의 Tool Call 생성 과정, (2) Guardrail 분류 결과, (3) 차단/허용 여부와 판정 사유를 단계별로 관찰할 수 있다.

② 직접 입력 탭

tool_call 등 5 개 입력 필드를 직접 작성하여 임의의 Tool Call 을 즉시 분류할 수 있다. 내부 보안 운영팀이 새로운 위협 시나리오를 테스트하는 용도로 활용 가능하다.

③ 추론 우선순위 (Inference Cascade)

HuggingFace 파인튜닝 모델 → KakaoCloud 엔드포인트 → Claude Haiku 폴백

1 순위 모델이 응답하지 않을 경우 자동으로 다음 단계로 폴백되어 가용성을 보장한다.

6.3 내장 시나리오

데모 시스템에는 카테고리별 대표 시나리오 6 종이 사전 내장되어 있어, 보안 위협 시연 및 교육에 즉시 활용 가능하다.

시나리오	카테고리	설명
날씨 검색	safe	공개 정보 검색, 위협 없음
고객 정보 이메일 전송	S1	주민번호·계좌번호 외부 전달
DB 비밀번호 Slack 공유	S2	운영 DB 인증정보 Webhook 전송
이메일 내 악성 명령	S3	이메일 본문의 숨겨진 명령 에이전트 탈취
고객 DB 구글 시트 업로드	S4	전화번호 포함 내부 데이터 외부 전달
시스템 지시사항 파일 저장	S5	내부 비밀번호·규칙 파일로 추출

데모 시나리오의 시연 및 활용방안

- 기업 보안팀 교육 : 실제 LLM 에이전트 위협 시나리오 시연
- 개발자 통합 테스트 : 자사 에이전트의 Tool Call 안전성 사전 점검
- 학술 연구 벤치마크 : 한국어 가드레일 평가 기준 자료로 활용

7. 결론 및 향후 계획

7.1 핵심 기여 (Key Contributions)

No.	기여 항목 (Contribution)
1	한국어 Tool Call 보안 탐지 특화 가드레일 최초 구현
2	7,000 건 한국어 합성 보안 데이터셋 구축 및 오픈소스 공개
3	프롬프트 반복 개선 방법론 정립: v1(75%) → v4(94%), FPR 0% 달성
4	Llama Guard 3 대비 한국어 환경 F1 +53%p 개선 (0.61 → 0.940)
5	실시간 추론 가능한 FastAPI 서버 및 라이브 데모 완성

7.2 향후 개발 계획 (Future Roadmap)

단계 (Phase)	목표 (Objective)	예상 성과 (Expected Outcome)
Kanana-8B DPO 학습	FPR ≤ 3%	과탐 최소화로 운영 환경 적합성 확보
실 운영 데이터 강화	엣지 케이스 해결	EDGE-003 등 경계 케이스 개선
tool_result 미들웨어	1,024 토큰 제한	대용량 입력 안정화
멀티에이전트 확장	Agent-to-Agent 보안	다중 에이전트 환경 지원

종합 결론

Guardrail4Agent 프로젝트는 한국어 환경에서 LLM 에이전트의 Tool Call 단계 보안 감시라는 미답 문제를 해결하기 위해, 합성 데이터 구축부터 모델 파인튜닝, 실시간 서빙, 라이브 데모에 이르는 전 과정을 약 2 개월 만에 완수하였다. 본 프로젝트의 모든 결과물(데이터셋, 모델, 코드)은 오픈소스로 공개되어 후속 연구 및 산업 적용의 기반이 될 것이다.

8. 부록 (Appendix)

A. 공개 리소스 (Open Resources)

- **GitHub 저장소** : <https://github.com/tristan-kkim/guardrail4agent>
- **HuggingFace 모델** : [tristan-kim/kanana-guardrail4agent](https://huggingface.co/tristan-kim/kanana-guardrail4agent)
- **라이브 데모** : <http://43-203-223-40.nip.io>

B. 참고 논문 (References)

- [1] Inan, H., et al. (2023). Llama Guard: LLM-based Input-Output Safeguard for Human-AI Conversations. Meta AI.
- [2] Hu, E. J., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685.
- [3] Rafailov, R., et al. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. NeurIPS.
- [4] Dao, T., et al. (2022). FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. NeurIPS.
- [5] KakaoAI (2025). Kanana: A Family of Compact Korean LLMs. Technical Report.

C. 평가 테스트 케이스 분포 (총 50 건)

카테고리	케이스 수	비율
safe	10 건	20%
S1 (PII)	8 건	16%
S2 (Credential)	8 건	16%
S3 (Prompt Injection)	8 건	16%
S4 (Data Exfiltration)	8 건	16%
S5 (System Prompt Extraction)	5 건	10%
Edge Cases	3 건	6%
합계 (Total)	50 건	100%

D. 라이선스 (License)

본 프로젝트의 모든 결과물(코드, 데이터셋, 모델)은 Apache License 2.0 으로 공개됩니다. 상업적 사용을 포함한 자유로운 활용이 가능하며, 저작자 표시 및 라이선스 명시를 요구합니다.

— E.O.D —